

مرور مقالات استفاده شده در ارائه

۱. Zhang et al., ۲۰۲۲ – “A Survey on Aspect-Based Sentiment Analysis”.

مقاله با عنوان "A Survey on Aspect-Based Sentiment Analysis" یکی از جامع‌ترین مراجع برای درک حوزه ABSA است. این مقاله به جای نگاه کلی به متن، روی اجزای دقیق‌تر تمرکز می‌کند.

بعد از تعریف تحلیل احساسات مبتنی بر جنبه به چهار عنصر اصلی (The Quadruple) اشاره می‌کند. ژانگ و همکارانش تأکید می‌کنند که یک تحلیل کامل شامل چهار بخش است جنبه **Aspect Term** : کلمه‌ای که به آن اشاره شده (مثل "غذا"). دسته‌بندی جنبه **Aspect Category** : دسته‌ای که جنبه به آن تعلق دارد (مثل "Quality" یا "Price"). احساس **Sentiment Polarity** : مثبت، منفی یا خنثی. عبارت نظر **Opinion Term** : کلماتی که نظر را بیان می‌کنند (مثل "عالی").

این مقاله روند پیشرفت تکنولوژی را در سه دوره بررسی می‌کند. روش‌های سنتی: استفاده از لغتنامه‌ها و قوانین دستوری. یادگیری ماشین کلاسیک: استفاده از ویژگی‌های دستی و مدل‌هایی مثل SVM. یادگیری عمیق **Attention Mechanisms** : استفاده از مدل‌های CNN, LSTM و به ویژه Deep Learning Pre-trained Models که به مدل کمک می‌کند بفهمد کدام کلمه به کدام جنبه مربوط است. عصر پیش‌آموزش (BERT) استفاده از BERT و مدل‌های زبانی بزرگ که امروزه استاندارد طلایی این حوزه هستند. مقاله به چند چالش مهم اشاره می‌کند که هنوز جای کار دارند: جملات پیچیده: وقتی چندین جنبه و چندین حس در یک جمله با هم ترکیب می‌شوند. جنبه‌های ضمنی (Implicit Aspects): وقتی نام جنبه مستقیماً در متن نمی‌آید (مثلاً "این گوشی خیلی گران است" به جنبه "قیمت" اشاره دارد بدون اینکه کلمه قیمت ذکر شود). کمبود داده: برای بسیاری از زبان‌ها یا حوزه‌های خاص، داده‌های برچسب‌گذاری شده کافی وجود ندارد.

۲. Tian et al., ۲۰۲۴ – Aspect-Based Sentiment Analysis with Context Denoising (NAACL Findings).

مقاله Tian et al. (۲۰۲۴) که در یافته‌های NAACL کنفرانس Findings منتشر شده، بر روی یکی از نقاط ضعف آزاده‌مندی در مدل‌های NLP تمرکز کرده است: «نویز در متن».

نام کامل مقاله معمولاً به موضوع Denoising (نویزدایی) اشاره دارد و حرف اصلی آن این است که هر کلمه‌ای در اطراف یک «جنبه» (Aspect) لزوماً حاوی اطلاعات مفید نیست و گاهی باعث گمراهی مدل می‌شود.

ایده اصلی: چرا به نویزدایی (Denoising) نیاز داریم؟

در مدل‌های سنتی ABSA، فرض بر این است که تمام کلمات موجود در جمله به نوعی به درک احساسات کمک می‌کنند. اما در واقعیت: برخی کلمات بی‌ربط هستند (Irrelevant). برخی کلمات گمراه‌کننده هستند (Conflicting/Ambiguous). در جملات طولانی، کلمات مربوط به یک جنبه دیگر ممکن است به عنوان "نویز" برای جنبه فعلی عمل کنند.

تیان و همکارانش در این مقاله پیشنهاد می‌دهند که قبل یا در حین تحلیل، باید اثر این کلمات مزاحم را خنثی کرد.

این مقاله از دو منظر به حل مسئله می‌پردازد: شناسایی کلمات کلیدی (Context Selection): مدل یاد می‌گیرد که کدام بخش‌های جمله واقعاً به جنبه مورد نظر (Aspect) مرتبط هستند. بازنمایی مقاوم (Robust Representation): مدل به گونه‌ای آموزش می‌بیند که حتی اگر نویز در جمله وجود داشته باشد (مثلًاً غلط املایی یا کلمات نامربوط)، بازنمایی (Embedding) نهایی جنبه تغییر زیادی نکند.

یکی از تکنیک‌های احتمالی که در این مقاله (و کارهای مشابه ۲۰۲۴) بر جسته شده، یادگیری تقابلی (Contrastive Learning) است.

مدل سعی می‌کند: ۱) جمله اصلی را در کنار نسخه «نویزدایی شده» قرار دهد و آن‌ها را به هم نزدیک کند. ۲) جمله اصلی را از جملاتی که معنای متفاوتی دارند (یا نویز مخرب دارند) دور کند.

این کار باعث می‌شود مدل یاد بگیرد که به «سیگنال» توجه کند و «نویز» را نادیده بگیرد.

۳. Tian et al., ۲۰۲۱ – Type-aware Graph Convolutional Networks for ABSA.

یکی از مقالات نوآورانه در حوزه ABSA است که بر بهبود نحوه استفاده از ساختار نحوی (Syntactic Structure) جملات تمرکز دارد.

مدل‌های قبلی که از شبکه‌های عصبی گراف (GCN) استفاده می‌کردند، معمولاً جمله را به یک گراف وابستگی (Dependency Graph) تبدیل می‌کردند. در این گراف، کلمات گره‌های گراف هستند و روابط دستوری بین آن‌ها (مثل فاعل بودن یا مفعول بودن) یال‌های گراف را تشکیل می‌دهند.

اما یک نقص بزرگ وجود داشت: مدل‌های قدیمی فقط به این توجه می‌کردند که آیا بین دو کلمه رابطه‌ای هست یا نه (یال وجود دارد یا خیر)، اما به "نوع رابطه" توجه نمی‌کردند. برای مثال، رابطه "متهم" با رابطه "صفت" قدرت و معنای متفاوتی در انتقال احساسات دارد.

تیان و همکارانش مدلی به نام T-GCN معرفی کردند که "نوع محور" یا "آگاه از نوع" است. نوآوری‌های اصلی آن‌ها عبارتند از:

در نظر گرفتن برچسب روابط: آن‌ها یال‌های گراف را فقط به صورت خطوط ساده در نظر نگرفتند، بلکه نوع رابطه (مثلاً nsubj, obj, amod) را هم به مدل فهماندند.

سازوکار توجه (Attention) روی روابط: مدل یاد می‌گیرد که کدام نوع از روابط دستوری برای تشخیص احساسات مهم‌تر هستند. مثلاً رابطه صفت به موصوف معمولاً بار احساسی قوی‌تری نسبت به یک حرف اضافه ساده دارد.

گراف جهت‌دار و وزن‌دار: برخلاف مدل‌های ساده، این مدل به جهت رابطه و وزن (اهمیت) هر رابطه نیز دقت می‌کند.

مدل بدین صورت عمل می‌کند: ۱) تبدیل جمله به گراف: ابتدا جمله توسط یک تجزیه‌گر (Parser) به گراف وابستگی تبدیل می‌شود. ۲) تزریق نوع روابط: به هر یال در گراف، یک ویژگی اضافه می‌شود که نشان‌دهنده نوع رابطه دستوری آن است. ۳) پردازش با GCN ارتقا یافته: شبکه عصبی گراف، اطلاعات هر کلمه را با توجه به همسایگانش و نوع پیوند با آن‌ها به روزرسانی می‌کند. ۴) استخراج احساس جنبه: در نهایت، مدل با ترکیب اطلاعات کلمه مربوط به "جنبه" (Aspect) و کلمات مرتبط با آن، نظر نهایی (ثبت/منفی) را اعلام می‌کند.

۴. Wu et al., ۲۰۲۱-Context-Guided BERT.

این مقاله به یکی از چالش‌های ظریف مدل‌های مبتنی بر BERT در تحلیل احساسات می‌پردازد. حرف اصلی این مقاله این است: «نباید با BERT مثل یک جعبه سیاه برخورد کرد؛ بلکه باید ساختار درونی آن را برای درک بهتر زمینه‌ی متن (Context) تغییر داد.»

در قبل، اکثر پژوهشگران برای استفاده از BERT در تحلیل احساسات (ABSA)، فقط متن را به مدل Self-دادند و خروجی لایه آخر را می‌گرفتند (مانند یک Blackbox). مشکل اینجا بود که مکانیزم

Attention در BERT به صورت عمومی عمل می‌کند و لزوماً روی بخش‌هایی از جمله که برای یک «جنبهٔ خاص» مهم هستند، تمرکز نمی‌کند.

وو و همکارانش مدلی به نام CG-BERT (Context-Guided MUFF) معرفی کردند. آن‌ها به جای اینکه فقط ورودی را تغییر دهند، ساختار محاسباتی داخل BERT را دستکاری کردند تا نسبت به «جنبهٔ هدف» (Aspect) و «هدف» (Target) حساس شود.

دو نسخه اصلی در این مقاله معرفی شده است: ۱) CG-BERT (Softmax-based): در این مدل، ماتریس‌های Query و Key در لایه‌های Attention توسط اطلاعات زمینه (Context) هدایت می‌شوند تا توجه مدل به کلمات مرتبط معطوف شود.

۲) QACG-BERT (Quasi-Attention): این نسخه پیشرفته‌تر است. در Attention معمولی، وزن‌ها همیشه مثبت هستند (بین ۰ و ۱). اما این مدل اجازه می‌دهد وزن‌ها منفی هم باشند (Subtractive Attention). چون گاهی اوقات برای درک یک حس، مدل باید روی برخی کلمات نویزدار یا گمراه‌کننده «تمرکز‌زدایی» کند یا اثر آن‌ها را کم کند.

این مقاله تأکید زیادی روی TABSA دارد. در TABSA معمولی می‌گوییم: "قیمت خوب است." (جنبهٔ قیمت). در TABSA می‌گوییم: "قیمت هتل A خوب است اما هتل B گران است."

در اینجا مدل باید بفهمد "خوب بودن" متعلق به هدف A است و "گران بودن" متعلق به هدف B. مدل CG-BERT با استفاده از راهنمای متنی، از خلط مبحث بین این هدف‌ها جلوگیری می‌کند.

در کل مقاله Wu et al. (۲۰۲۱) می‌گوید: برای اینکه BERT در تحلیل احساسات دقیق‌تر عمل کند، باید به آن یاد بدھیم که «چشم‌بسته به همه کلمات نگاه نکند»، بلکه با توجه به جنبه‌ای که مد نظر ماست، توجه (Quasi-Attention) خود را به صورت هوشمندانه و حتی با حذف اثر کلمات غیرمرتب (Aspect-Based Sentiment Analysis) تنظیم کند.

۵. Understanding Consumer Opinions with Aspect-Based Sentiment Analysis: An Amazon Review Case Study (IJSREM).

این مقاله که در مجله IJSREM منتشر شده، یک مطالعه موردی (Case Study) کاملاً کاربردی است. هدف اصلی: فروشگاه آمازون میلیون‌ها نظر کاربر دارد. یک مدیر محصول نمی‌تواند تمام نظرات را بخواند تا بفهمد چرا مردم از یک محصول ناراضی هستند.

الف) هدف: ارائه سیستمی که به طور خودکار بفهمد کاربران درباره کدام ویژگی‌های خاص یک محصول (مثلًاً باتری، طراحی، قیمت) چه حسی دارند. ب) جامعه هدف: کسبوکارها و تیم‌های بازاریابی که می‌خواهند بر اساس نقدهای واقعی مشتریان، محصول خود را بهبود دهند.

در این مقاله معمولاً از ترکیبی از روش‌های زیر استفاده شده است: الف) برای TextBlob یا VADER: برای تشخیص اولیه حس (ثبت/منفی). ب) برای پیدا کردن ترکیب کلمات (مثل "Long-lasting") که برای باتری مثبت است. ج) LDA (Latent Dirichlet Allocation): احتمالاً برای دسته‌بندی موضوعی نظرات و پیدا کردن خودکار جنبه‌ها (Aspects).

این مقاله نشان می‌دهد که: تحلیل کلی (Sentiment Analysis معمولی) فریب‌دهنده است. مثلاً محصولی که امتیاز ۴ از ۵ دارد، ممکن است در جنبه "دوم" افتضاح باشد اما چون "ظاهر" خوبی دارد امتیاز بالای گرفته باشد. ABSA این نقطه ضعف مخفی را پیدا می‌کند. مدل طراحی شده توانسته است با دقت قابل قبولی، نظرات مثبت و منفی را تفکیک کند و به فروشنده بگوید دقیقاً کدام بخش محصولش نیاز به اصلاح دارد.

۶. Investigation of challenges in aspect-based sentiment analysis ... during the ۲۰۲۴ Indonesian presidential election(Procedia Computer Science , ۲۰۲۴).

یک پژوهش کاربردی است که از تکنولوژی NLP برای تحلیل فضای سیاسی استفاده کرده است. در حقیقت، نویسنده‌گان می‌خواستند بفهمند مردم اندونزی در توئیتر (X) درباره کاندیداهای ریاست جمهوری ۲۰۲۴ چه نظراتی دارند، اما نه به صورت کلی؛ بلکه می‌خواستند بدانند چالش‌های تحلیل دقیق این نظرات (بر اساس جنبه‌های مختلف مثل اقتصاد، شخصیت کاندیدا و...) چیست.

در این راستا، آن‌ها از مدل‌های یادگیری عمیق (Deep Learning) استفاده کردند که با تابع Softmax تقویت شده بود تا بتوانند نظرات را با دقت بیشتری دسته‌بندی کنند.

اهمیت این کار از این جهت بود که در انتخابات، نظرات مردم بسیار پیچیده و پر از کنایه (Sarcasm) و لغات عامیانه است. هدف این مقاله شناسایی موانعی است که باعث می‌شود سیستم‌های هوش مصنوعی در تشخیص درست این نظرات دچار خطأ شوند.

مقاله به طور خاص روی چالش‌هایی تمرکز می‌کند که در داده‌های توئیتر اندونزی وجود دارد:

الف) زبان عامیانه و غیررسمی: مردم در انتخابات از اصطلاحات خاص و کلمات کوتاهشده استفاده می‌کنند که مدل‌های استاندارد آن‌ها را نمی‌فهمند.

ب) چندجنبه‌ای بودن جملات: یک تؤییت ممکن است همزمان از اخلاق یک کاندیدا تعریف کند اما به برنامه‌های اقتصادی اش نمره منفی بدهد. تفکیک این دو در محیط پر از نویز تؤییتر چالش اصلی است.

ج) نامتعادل بودن داده‌ها (Data Imbalance): در طول انتخابات، ممکن است طرفداران یک کاندیدا بسیار فعال‌تر باشند و این باعث شود مدل به نفع یک سمت خاص سوگیری (Bias) پیدا کند.

این پژوهش نشان داد که با استفاده از توابع فعال‌ساز بهینه مثل Softmax، می‌توان نرخ خطای تحلیل احساسات را در محیط‌های پرتنشی مثل انتخابات کاهش داد. با این حال، مقاله تأکید می‌کند که "درک بافت فرهنگی و زبانی" (Context) هنوز بزرگترین مانع برای رسیدن به دقت ۱۰۰٪ در تحلیل‌های سیاسی است.

۷. Aspect-based sentiment analysis for software requirements elicitation (ScienceDirect, ۲۰۲۵).

این مقاله به یکی از جذاب‌ترین کاربردهای ABSA را در شاخه مهندسی نرم‌افزار می‌پردازد. وقتی شرکت‌های بزرگ (مثل گوگل یا مایکروسافت) می‌خواهند نسخه جدید یک برنامه را بسازند، هزاران نظر، ایمیل و گزارش باگ از کاربران دریافت می‌کنند. مهندسان نرم‌افزار نمی‌توانند همه این‌ها را بخوانند تا بفهمند کاربران چه "نیازمندی‌های" جدیدی دارند.

هدف اصلی مقاله، استفاده از ABSA برای استخراج خودکار نیازمندی‌های نرم‌افزاری (Requirements Elicitation) از میان نظرات کاربران. یعنی تبدیل "نظرات عامیانه" به "لیست وظایف برنامه‌نویسان".

نویسنده‌گان یک فرآیند هوشمند طراحی کرده‌اند که نظرات را به نیازمندی تبدیل می‌کند: ۱) شناسایی ویژگی‌های نرم‌افزار (Features as Aspects): مدل یاد می‌گیرد که مفاهیمی مثل "سرعت لود"، "امنیت ورود"، یا "رابط کاربری" را به عنوان Aspect شناسایی کند. ۲) تحلیل شدت نارضایتی: در اینجا فقط مثبت/منفی مهم نیست. مدل روی احساسات منفی تمرکز می‌کند تا بفهمد "درد" اصلی کاربر کجاست. ۳) اولویت‌بندی (Prioritization): این بخش نوآوری اصلی است. مقاله سیستمی ارائه می‌دهد که بر اساس تعداد نظرات منفی و اهمیت آن جنبه، به مدیر پروژه می‌گوید: «اول این باگ را رفع کن!»

چالش‌های که مقاله حل کرده است: ابهام در کلام کاربران و استخراج پیشنهادها، به این معنی که علاوه بر حس، کلمات کلیدی که نشان‌دهنده یک "درخواست" هستند (مثل "I wish", "Better to have") را شناسایی کند.

۸. Aspect-based sentiment analysis of user-generated content from a microblogging platform(*Journal of Big Data*, ۲۰۲۵).

این مقاله، یک پله از مقالات قبلی بالاتر است؛ چرا که روی «داده‌های بزرگ» (Big Data) و چالش‌های خاص پلتفرم‌های میکروبلاگینگ (مثل Threads X/Twitter سابق یا) تمرکز دارد.

میکروبلاگ‌ها (مثل توئیتر) با سایتهاي مثل آمازون فرق دارند. در آمازون کاربر وقت می‌گذارد و نقد می‌نویسد، اما در میکروبلاگ: (الف) جملات بسیار کوتاه و تلگرافی هستند. (ب) کاربران از هشتگ‌ها (#) برای بیان جنبه‌ها استفاده می‌کنند. (ج) سرعت تولید محتوا وحشتناک زیاد است (Big Data).

هدف از انجام پروژه و تحریر مقاله، طراحی سیستمی که بتواند در لحظه (Real-time)، حجم عظیمی از داده‌های کوتاه و شلوغ را تحلیل کند و بفهمد افکار عمومی درباره موضوعات مختلف (سیاست، برندها، حوادث) چه سمتی می‌رود.

برخلاف مقاله آمازون که ساده بود، این مقاله با ترکیب چند روش سعی در بالا بردن تا دقیقت را دارد:

۱) مدل‌های زبانی بزرگ (LLMs): از نسخه‌های بهینه‌شده RoBERTa یا BERT برای درک معنای کلمات در جملات کوتاه استفاده کرده است.

۲) تحلیل گراف (Graph-based): به جای اینکه فقط کلمات را پشت سر هم بینند، ارتباط بین کاربران، هشتگ‌ها و کلمات را به صورت یک شبکه (Graph) تحلیل کرده تا بفهمد نفوذ یک نظر چقدر است.

۳) مدیریت نویز: چون در توئیتر ربات‌ها و اسپیم‌ها زیاد هستند، این مقاله یک بخش اختصاصی برای فیلتر کردن داده‌های بی‌ارزش قبل از تحلیل احساسات دارد.

این مقاله به این دلیل در *Journal of Big Data* چاپ شده که دو چالش بزرگ را حل کرده است:

۱. مقیاس‌پذیری (Scalability): مدل آن‌ها طوری طراحی شده که می‌تواند میلیون‌ها توئیت را در زمان کوتاهی پردازش کند (استفاده از محاسبات موازی).

۲. درک کلمات نوظهور: در میکروبلاگ‌ها کلمات و اصطلاحات جدید خیلی زود ساخته می‌شوند. این مدل از روشی به نام Continual Learning استفاده کرده تا بدون نیاز به آموزش مجدد کل سیستم، کلمات جدید را یاد بگیرد.

چالش های کاربرد ABSA در این حوزه که مقاله به آن اشاره شده است: (الف) تشخیص هدف (Target Identification)؛ در یک توصیت کوتاه، تشخیص اینکه "عالی بود" به کدام کلمه برمی‌گردد سخت است. آنها از مکانیزم Multi-head Attention استفاده کردند تا پیوند دقیق بین صفت و موصوف را پیدا کنند. (ب) تنوع موضوعی: این مدل برخلاف مدل‌های قبلی، فقط برای یک محصول (مثل موبایل) نیست؛ بلکه می‌تواند همزمان درباره «واکسن»، «بیت‌کوین» و «فوتبال» با دقت بالا نظر بدهد.